Lab 2: Dữ liệu và Tiền xử lý

Mục tiêu:

- Hiểu các loại dữ liệu và cách xử lý dữ liệu thô.
- Thực hiện làm sạch dữ liệu (xử lý giá trị thiếu, ngoại lệ).
- Thực hiện chuẩn hóa dữ liệu (Scaling).
- Chia dữ liệu thành tập huấn luyện (Train) và tập kiểm tra (Test).
- Làm quen với khái niệm Pipeline cơ bản.

Bài 1: Làm sạch dữ liệu

Yêu cầu:

- Tạo một DataFrame chứa dữ liệu bị thiếu (NaN) và có giá trị ngoại lệ (outlier).
- Sử dụng Pandas để:

1. Điền các giá trị thiếu bằng giá trị trung bình (mean) của cột.
2. Phát hiện và xử lý giá trị ngoại lệ đơn giản (ví dụ: các giá trị lớn hơn 3 lần độ lệch chuẩn).

Bài 2: Chuẩn hóa dữ liệu (Scaling)

Yêu cầu:

- Tạo một mảng dữ liệu có các cột với đơn vị khác nhau (ví dụ: Tuổi từ 20-60 và Thu nhập từ 10tr-100tr).
- Sử dụng StandardScaler và MinMaxScaler từ thư viện sklearn.preprocessing để chuẩn hóa mảng dữ liệu này.
- In kết quả sau khi chuẩn hóa để so sánh.

Bài 3: Chia tập dữ liệu Train/Test

Yêu cầu:

- Sử dụng tập dữ liệu diabetes từ sklearn.datasets.
- Sử dụng hàm train_test_split để chia dữ liệu thành 2 tập: train (80%) và test (20%).
- In ra kích thước của tập dữ liệu gốc và kích thước của hai tập sau khi chia.

Bài 4: Quy trình ML hoàn chỉnh - Phần 2: Tiền xử lý dữ liệu

Yêu cầu:

- Tiếp tục với tập dữ liệu digits từ Lab 1.
- Thực hiện các bước tiền xử lý:

1. Chuẩn hóa dữ liệu (Scaling) vì giá trị pixel nằm trong khoảng 0-16.
2. Chia tập dữ liệu thành Train và Test.
3. Xây dựng một Pipeline đơn giản chứa bước chuẩn hóa và một model (ví dụ: SVM hoặc Logistic Regression).

Bài 5: Giảng viên giao thêm