Lab 7: Học kết hợp và Chuẩn bị Mini Project

Mục tiêu:

- Làm quen với các thuật toán Ensemble Learning, cụ thể là Random Forest.
- Hiểu được lợi ích của việc sử dụng các mô hình phức tạp (Ensemble) so với các mô hình đơn giản (như Decision Tree đơn lẻ).
- Ôn tập lại việc xây dựng một Machine Learning Pipeline hoàn chỉnh.
- Bắt đầu chuẩn bị cho Mini Project.

Bài 1: Sử dụng Random Forest Classifier

Yêu cầu:

- Tải tập dữ liệu 'wine' từ 'sklearn.datasets'.
- Chia dữ liệu thành tập Train và Test (tỷ lệ 80/20).
- Khởi tạo và huấn luyện hai mô hình: 'DecisionTreeClassifier' và 'RandomForestClassifier'.
- Dự đoán và tính toán độ chính xác (accuracy) của cả hai mô hình trên tập Test.
- So sánh kết quả.

Bài 2: Xây dựng Pipeline hoàn chỉnh

Yêu cầu:

- Giả sử bạn đang làm việc với một tập dữ liệu có giá trị khuyết thiếu (missing values) và cần được chuẩn hóa.
- Tạo một tập dữ liệu giả với một vài giá trị NaN.
- Sử dụng 'Pipeline' từ 'sklearn.pipeline' để nối các bước sau:

1. 'SimpleImputer' (để điền giá trị khuyết thiếu bằng trung bình).

2. 'StandardScaler' (để chuẩn hóa dữ liệu).
3. 'RandomForestClassifier'.

- Huấn luyện 'Pipeline' này trên dữ liệu.

Bài 3: Chuẩn bị dữ liệu cho Mini Project

Yêu cầu:

- Sử dụng 'pandas' để tải tập dữ liệu phân loại hoặc hồi quy từ một URL công khai (ví dụ: tập dữ liệu Titanic hoặc Iris từ seaborn/github). Ở đây ta có thể dùng URL của tập dữ liệu Titanic: 'https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv'.
- Hiển thị 5 dòng đầu tiên.
- Thực hiện kiểm tra thông tin dữ liệu ('.info()') và tóm tắt thống kê ('.describe()').
- Nhận diện các cột có giá trị khuyết thiếu.

Bài 4: Chương trình Demo Pipeline kết hợp GridSearchCV

Yêu cầu:

- Áp dụng 'Pipeline' đã học để giải quyết tập dữ liệu 'breast_cancer'.
- Xây dựng Pipeline gồm: 'StandardScaler' và 'RandomForestClassifier'.
- Sử dụng 'GridSearchCV' để tinh chỉnh siêu tham số cho Random Forest bên trong Pipeline:
- 'randomforestclassifier__n_estimators': [50, 100, 200]
- 'randomforestclassifier__max_depth': [None, 10, 20]
- In ra tham số tốt nhất và độ chính xác tương ứng.

Bài 5: Giảng viên giao thêm.