Bài 2:Tiền xử lý
*Tầm quan trọng của: Dữ liệu + Tiền xử lý dữ liệu
Dữ liệu thô như “Dầu mỏ” => vô giá trị nếu không được tinh chế (tiền xử lý)
*thời gian tiền xử lý chiếm 80% cho ML
*Các loại dữ liệu thực tế:
-Dạng bảng (Excel, SQL)
-Dạng phi cấu trúc: Văn bản, hình ảnh, video, âm thanh
-Số: đếm được, khoảng số thực
-Dữ liệu phân loại: Định danh (màu sắc) + có thứ tự (độ hài lòng)

Làm sạch dữ liệu thế nào???
Xử lý giá trị thiếu (Missing Values) + giá trị ngoại lệ (Outliers)
Cách xử lý giá trị thiếu:
-Ký hiệu: NaN, None, ô trống
-Xử lý:
+Xóa (dòng nếu thiếu ít,cột nếu thiếu quá nhiều > 50-60%)
+điền giá trị thiếu bằng Mean (trung bình); Median (trung vị); Mode (yếu vị) hoặc hằng số
*Cách xử lý giá trị ngoại lệ: (là các giá trị cách xa so với phần còn lại) => xác định ngoại lệ bằng biểu độ Botplot hoặc quy tắc IQR
-Xử lý:
+Loại bỏ
+biến đổi log
+cắt biên (Winsorization)

Chuẩn hóa (Scaling), mã hóa (Encoding):
Chuẩn hóa:
-Tránh việc các cột có giá trị lớn (vd: lương) lấn át cột có giá trị nhỏ (vd: tuổi)
-Sử dụng MinMaxScaler (đưa về khoảng từ 0 đến 1)
-StandardScaler (đưa về trung bình bằng 0, độ lệch bằng 1)
Encoding: Chuyển đổi dữ liệu chữ sang số
-Label Encoding: gán số nguyên cho dữ liệu có thứ bậc

-One-Hot Encoding: tạo cột giả (0, 1) cho dữ liệu định danh để tránh hiểu lầm về thứ tự

Chia tập dữ liệu

Features (X) và Label (Y): là tập các đặc trương đầu vào, với yyy là nhãn mục tiêu cần dự đoán (y=f(X)y = f(X)y=f(X))

Train hoặc Test Split:

Chia dẽ liệu thành tập huấn luyện (Train: 70-80%) để máy học tập (Test: 20-30%) để đánh giá năng lực thực tế

chú ý: Không bao giờ cho máy nhìn thấy tập test trước

Rò rỉ dữ liệu (Data Leak): nghĩa là dữ liệu Test vị lẫn vào quá trình huấn luyện

---

Tóm lại:

-Tiền xử lý dữ liệu là bước cốt lõi, quyết định 80% của ML

-Cần xử lý triệt để giá trị khuyết thiếu (NaN) bằng cách điền Mean, Median, Mode

-Phát hiện và xử lý ngoại lệ (Outliers) để tránh làm sai mô hình

-Chuẩn hóa (scaling) để đưa các đặc trưng về cùng 1 thang đo và mã hóa (Encoding) dữ liệu sang số

-Chia dữ liệu thành tập Train và Test, kết hợp Pipeline để tự động hóa quy trình

---

Demo:

```
#1.Cau hinh moi truong ML
import numpy as np
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
print("=====1. Làm sạch dữ liệu========")
data = {
  "Tuổi": [22,25,np.nan,29,45,150],
  "Điểm_Thi": [8.0,np.nan,6.5,9.0,5.5,4.0]
}
df=pd.DataFrame(data)
#1.1 Thong ke tổng số lượng giá trị bị thiếu (NaN) trên từng cột
print("1. Số lượng giá trị thiếu (NaN) trên từng cột:\n",df.isnull().sum())
#1.2 ĐIền giá trị thiếu ở cột ĐIểm_Thi bằng giá trị trung vị (Median)
median_diem = df["Điểm_Thi"].median()
```

```
df["Điểm_Thi"]=df["Điểm_Thi"].fillna(median_diem)
#1.3 Xử lý giá trị ngoại lệ ở cột Tuổi (loại bỏ dòng chứa tuổi >100)
df=df[df["Tuổi"]<=100]
print("\nDataFrame sau khi làm sạch dữ liệu:\n",df)
print("=====2. Chuẩn hóa và mã hóa==========")
#2.1 Chuan hóa (Scaling) với StandardScaler
thu_thap_kinh_nghiem=[
  [1000000,1],
  [2500000,5],
  [1500000,2],
  [4000000,8]
]
scaler = StandardScaler()
scaled_data = scaler.fit_transform(thu_thap_kinh_nghiem)
print("1. Dữ liệu sau khi chuẩn hóa (Mean=0, Std=1):\n",scaled_data)
#2.2 Mã hóa kích thước quần:
#Kích thước quần có thứ bậc S<M<L<XL => sử dụng LabelEncoder là phù hợp vì nó giữ
lại trật tự kích thước
kich_thuoc=["S","M","L","XL","M","S"]
df_size = pd.DataFrame({"Kich_Thuoc":kich_thuoc})

encoder = LabelEncoder()
df_size["Encoded"]=encoder.fit_transform(df_size["Kich_Thuoc"])
print("\n2. Kết quả mã hóa kích thước quần bằng LabelEncoder:\n",df_size)
print("=====3. Chia tập dữ liệu Train/Test")
#Tải tập dữ liệu Iris
iris=load_iris()
X=iris.data
y=iris.target
#Chia dữ liệu theo tỷ lệ 80:20, cố định random_state
X_train,X_test,y_train,y_test = train_test_split(X,y,test_size=0.2,random_state=42)
print("Kich thước tạo X_train: ",X_train.shape)
print("Kich thước tạo X_test: ",X_test.shape)
print("Kich thước tạo y_train: ",y_train.shape)
print("Kich thước tạo y_test: ",y_test.shape)
```